

# 姿勢推定 AI を用いたヒューマノイド向けデータセット構築

2025 年 1 月 27 日  
3 年 5 組 26 番 野澤和真

## 1. 背景について

日本は世界有数の少子高齢化社会であり、総務省の推計によると 2023 年の総人口は 1 億 2242 万人で、過去最高の減少幅を記録した。出生数が年々低下を続ける中で、労働力人口の減少は経済社会に深刻な影響を及ぼしている。政府や自治体は様々な対策を講じてきたものの、人口減少の流れを根本的に変えることはできていない。たとえば、労働参加率の向上や外国人労働者の受け入れ拡大といった施策は一定の効果を上げているものの、労働人口の減少スピードに追いついていないと言え難い現状がある。このような社会課題に対して、汎用的なタスクをこなすヒューマノイドロボットの活用が有力な解決策の一つとして期待されている。ヒューマノイドは人間と同様の二足歩行を行い、人間が設計した環境で作業が可能であるため、労働力不足分を補完する可能性を秘めている。

近年の技術進展もこの期待を後押ししている。大規模言語モデル (LLM) のマルチモーダル化により、映像や画像を理解し言葉で説明する能力が飛躍的に向上した。2025 年の NVIDIA Keynote では「Physical AI」という概念が提唱され、AI が物理世界と直接対話する時代の到来が示唆された。これらの技術革新は、ヒューマノイドロボットの知性と身体能力を飛躍的に向上させる原動力となりつつある。実際に、Boston Dynamics の Atlas や Tesla の Optimus、Figure 03、Unitree Robotics の製品など、複数の企業が実用化に向けた開発競争を展開しており、ヒューマノイドが日常生活や産業現場に溶け込む未来は現実味を帯びてきた。しかしながら、これらの先進的なロボットの開発には依然として大きな課題が横たわっている。

## 2. 既存・研究中の技術について

既存のヒューマノイドロボット開発において最大の障壁は、ロボットにタスクを学習させるためのデータセット作成にかかる膨大なコストである。各社のヒューマノイドは独自のハードウェア設計を採用しており、関節の可動域やリンク長、トルク特性などが大きく異なる。このため、あるロボット向けに収集したデータは他のロボットにはそのまま流用できず、ハードウェアに特化したデータセットをゼロから構築する必要がある。従来のデータ収集方法は、まず高価な実機ロボットを用意し、そのロボットを使って実際に動作を収録するというアプローチが主流であった。さらに正確な動作データを取得するためには、大掛かりなモーションキャプチャシステムの設置や、VR を用いた遠隔操作システムの構築が不可欠であった。これらの設備は数千万円単位の投資を要し、高い技術的専門性も求める。結果として、データ作成のコストは極めて高く、一部の資本力のある企業や大学の研究機関にしか手が出ない状況が続いていた。この現状は、ヒューマノイドロボット技術の発展を特定の組織に制限する要因となり、イノベーションの速度を鈍化させる一因となっている。

一方で、コンピュータビジョン分野における姿勢推定技術は著しい進歩を遂げている。深層学習を用いた最新の姿勢推定 AI は、単眼カメラの映像からでも人間の関節位置を高精度で推定可能となり、さらには時間軸を加味した複数カメラ映像から 3 次元の骨格情報を復元する技術も実用化の段階に達している。しかしながら、これらの技術成果はヒューマノイドロボットのデータセット作成には十分に活かされていない。映像アーカイブという膨大なリソースがあるにもかかわらず、それをロボット学習データとして変換する効率的なパイプラインが確立していないのが現状である。既存研究では、特定のタスク向けに手動でデータを収集するケースが多く、自動化やスケーラビリティという観点で欠落していた。このギャップこそが、本提案が解決すべき核心的な課題である。

## 3. 提案する製品について

本提案は、既存の映像アーカイブから姿勢推定 AI を活用してヒューマノイド向けデータセットを自動生成するパイプラインを提供するものである。このシステムの基本的な流れは以下の通りである。まず、人間がタスクを行っている映像を入力データとして用意する。これは YouTube などの公開映像、監視カメラの記録、実験用に撮影した動画など、任意の映像ソースが利用可能である。次に、この映像を最新の姿勢推定 AI に通すことで、人間の骨格情報を 3 次元で抽出する。具体的には、各関節の 3 次元座標や回転

角度、時間変化などが数値データとして取得される。この骨格情報は、人間の身体構造を表現したものであるため、後工程で任意のヒューマノイドロボットの構造にマッピングすることが可能となる。つまり、人間が掃除をする映像からは掃除動作の骨格データが生成され、組立作業の映像からは組立動作のデータが生成される。これにより、膨大な種類のタスクデータを低コストで量産できる基盤が完成する。

本手法の最大の差別化ポイントは圧倒的な低コストである。従来のモーションキャプチャシステムやVR操作設備を必要としないため、初期投資を数百万円から数万円規模に削減できる可能性がある。さらに、インターネット上の膨大な映像アーカイブを利用できるため、データ量の確保が極めて容易になる。従来は1つのタスクについて数時間から数日かけて収集していたデータが、公開映像を介して短時間で何千時間分も構築可能となる。最も重要な点は、より高次の抽象度で人間の動作をデータとして保持するため、後から異なった構造のヒューマノイドモデルにも適用できる柔軟性を持つことである。たとえば、同じ「ドアを開ける」動作データでも、AtlasとUnitreeのような別の特性を持つロボットに対して、それぞれの構造に合わせて運動学的に異なる動作計画を生成できる。この変換にはIK（逆運動学）ソルバーや、シミュレーション環境でのオフライン最適化を適用する。これにより、データセットの再利用性が飛躍的に向上し、ロボット開発の効率化に大きく貢献する。新規性は、コンピュータビジョンの成果をロボティクスに橋渡しするという発想にあり、単なるデータ収集ツールを超えて、クロスロボットプラットフォームを実現する基盤技術としての位置づけを持つ。

#### 4. おわりに

本提案は、ヒューマノイドロボット開発における高価な機材や実機への依存を排除し、映像さえあればデータセット作成が可能になる新しいパラダイムを提供する。姿勢推定AIを活用した自動生成パイプラインにより、従来は一部の研究機関に限られていたデータ収集作業が、より多くの開発者や中小企業、教育機関でも実行可能になる。これは技術開発の民主化を促進し、イノベーションの加速に貢献するものと期待される。ただし、実現に向けてはいくつかの課題が残されている。まず、映像から直接ロボットの関節トルクやfootstep計画を生成するには、物理的な制約を考慮した追加の処理が必要となる。シミュレーション環境で収集データをフィルタリングし、安定性や衝突判定を加味したデータ精製プロセスを構築する必要がある。次に、カメラ角度や照明条件のばらつき、被写体の個人差に対するロバスト性向上も重要な開発項目である。さらに、著作権を含む映像利用の倫理的・法的フレームワークの整備も必要不可欠である。今後は、これらの課題に対して実装レベルでのアプローチを進め、実際のヒューマノイドロボットを用いた検証実験を通じて、データ品質と学習効果の評価を行う予定である。本技術が普及すれば、映像という日常的なメディアがロボットの知能を育む土壌として機能し、人間と共存するヒューマノイドの実現が一気に近づくものと信じている。

#### 5. 参考文献

- 総務省統計局. (2023). 人口推計. 日本の統計.
- Boston Dynamics. (2024). Atlas | Boston Dynamics. <https://bostondynamics.com/atlas>
- Tesla, Inc. (2024). Tesla Bot | Tesla. <https://www.tesla.com/AI>
- Figure AI. (2024). Figure 03.
- Unitree Robotics. (2024). Humanoid robots. <https://www.unitree.com>
- NVIDIA Corporation. (2025). CES 2025 Keynote.
- Cao, Z., Hidalgo Martinez, G., Simon, T., Wei, S., & Sheikh, Y. A. (2021). OpenPose: realtime multi-person 2D pose estimation using Part Affinity Fields. IEEE Transactions on Pattern Analysis and Machine Intelligence.
- von Marcard, T., Henschel, R., Black, M., Rosenhahn, B., & Pons-Moll, G. (2018). Recovering accurate 3D human pose in the wild using IMUs and a moving camera. European Conference on Computer Vision.